Clusters

Григорий Хазанкин , Данила Ковалёв

Кратко о главном

Что?

Виртуализация -
создание виртуальной (а не фактической) версии чего-либо, включая компьютерные платформы, устройства хранения данных и ресурсы компьютерной сети.

Виртуализация началась в 1960-х годах как метод логического разделения системных ресурсов, предоставляемых мэйнфреймами между различными приложениями. С тех пор значение этого термина расширилось.

Кратко о главном

Как?

- Grid computing
- …
- MOSIX, Linux-HA, Windows Server
- …
- Supercomputer

Зачем?

- Увеличение скорости вычислений
- Балансировка нагрузки
- Обеспечение отказоустойчивости
- Абстрагирование от аппаратуры
- Сервис облачных вычислений

Grid & Supercomputer

Grid:

- Узлы разнородны (Win, UNIX) подключены к сети (локальной или глобальной) при помощи стандартных протоколов (Ethernet)
- Узел ненадежен и может отсоединиться в любой момент
- Такая нестабильность компенсируется большим количеством узлов

Supercomputer:

- Узлы однородны, подключены к высокоскоростной коммутируемой компьютерной сети (InfiniBand, FC)

Grid & Supercomputer

Пример Grid:
Моделирование свертывания белка в Стэнфорде

FOLDING@HOME

- 222 000 CPU & 23 000 GPU
- Intel, AMD, Cell, AMD/NVIDIA GPU
- 7 PetaFLOPS (2011)
- Архитектура «клиент-сервер»

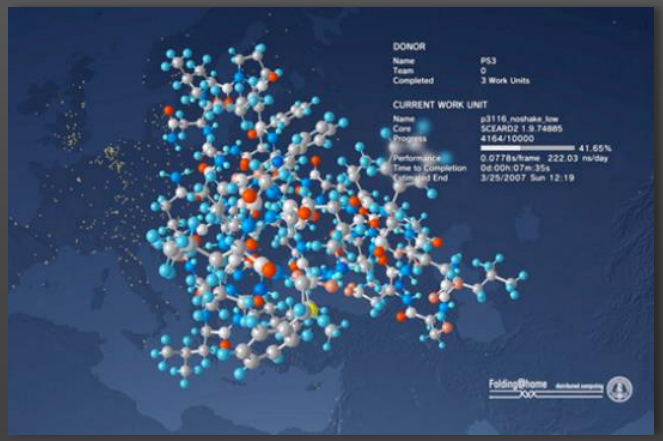

Grid & Supercomputer

Пример Supercomputer:
Оборонный научно-технический университет НОАК

天河二號, Tiānhé-2

- 33,86 PetaFLOPS
- состоит из

16 тысяч узлов
(2 процессора Intel Xeon E5-2692 на архитектуре Ivy Bridge с 12 ядрами (частота 2,2 ГГц)
и 3 сопроцессора IntelXeon Phi 31S1P

- СХД 12,4 ПБ

Аппаратурная архитектура. Supercomputer

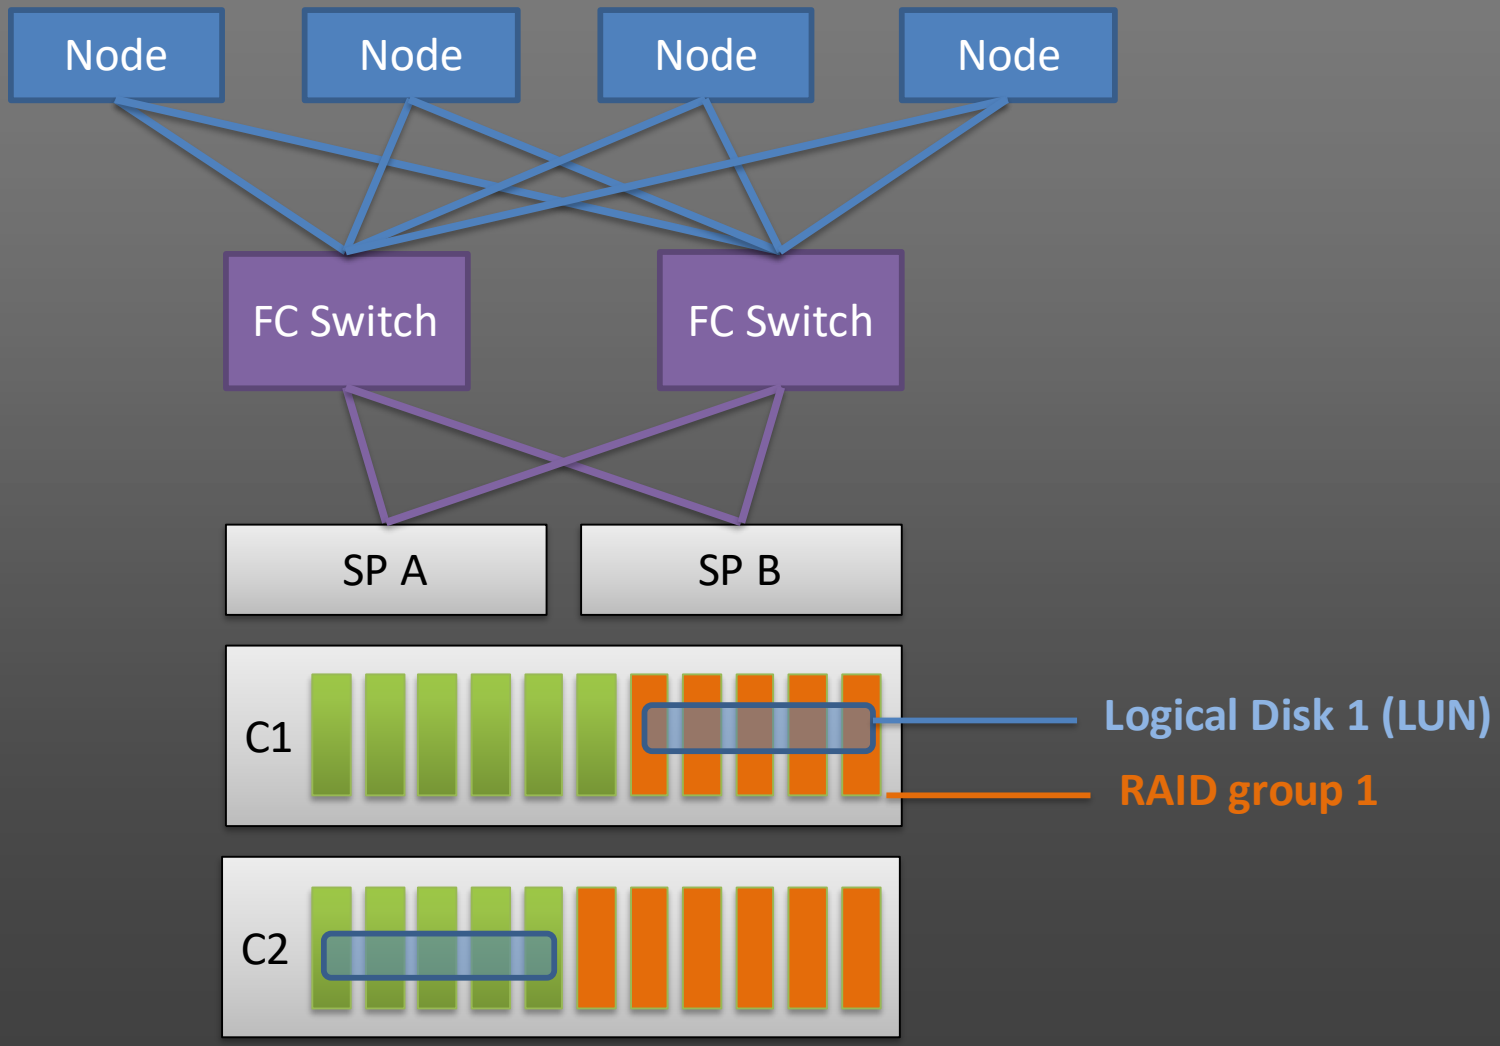

Computational clusters

Использование: ресурсоемкие вычисления

MPI (MPICH, Open MPI)

Hadoop

LB & HA clusters

Задача кластеров высокой доступности
High-availability clusters / failover clusters -
организовать надежный доступ к сервисам путем обеспечения отказоустойчивости.

Задача кластеров балансировки
Load balancing clusters –
распределение нагрузки между нодами (вершинами) кластера для повышения производительности.

LB & HA clusters. Example (Normal)

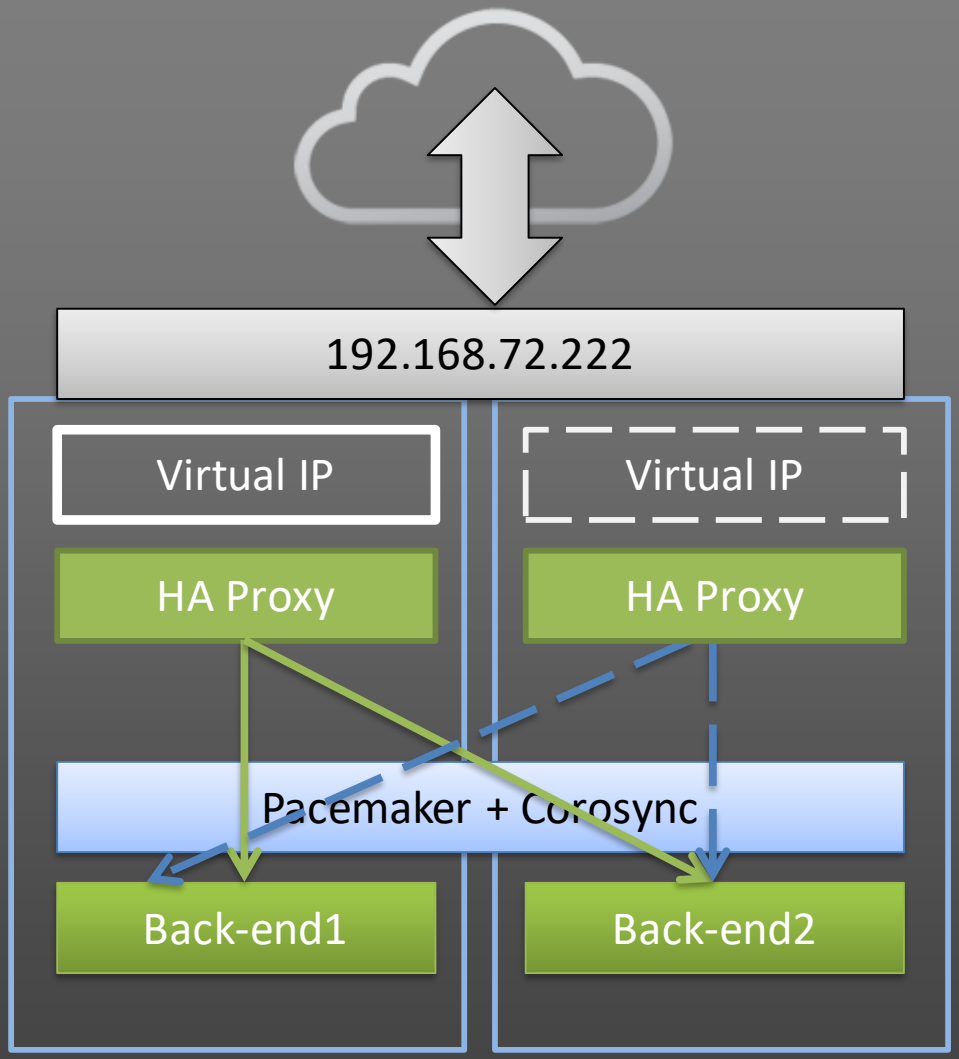

LB & HA clusters. Example (Fail)

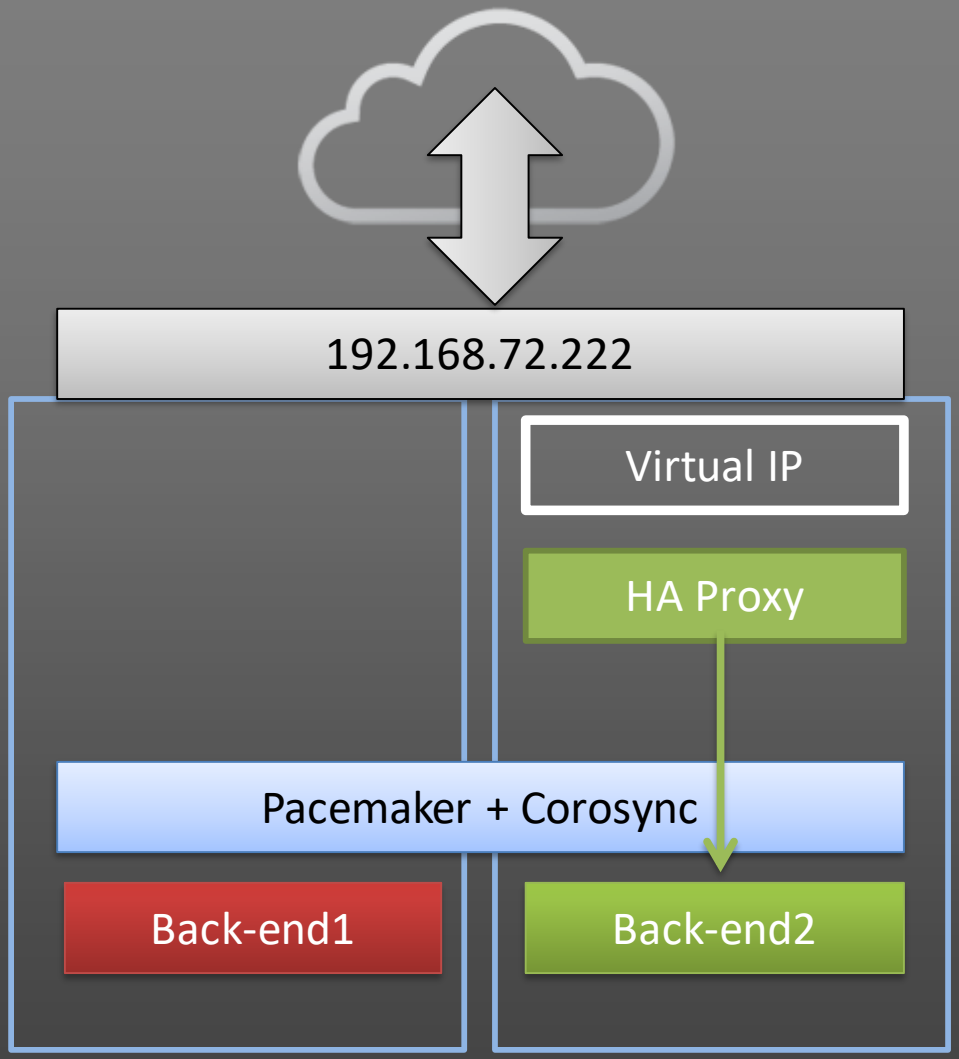

Принцип работы HA. Ресурсы

- Все, что может быть заскриптовано, то может быть ресурсом. Все, что требуется от скрипта, это выполнять 3 действия: start, stop и monitor. Скрипты должны соответствовать LSB (Linux Standard Base) или OCF (Open Cluster Framework).
  Ресурс может представлять из себя:
  ip-адрес, демон с определенной конфигурацией, блочное устройство, файловую систему и т.д.

- Ресурс соответственно должен уметь хранить свое состояние таким образом, чтобы его можно было с минимальными потерями перенести на другую ноду

Принцип работы HA. Ресурсы

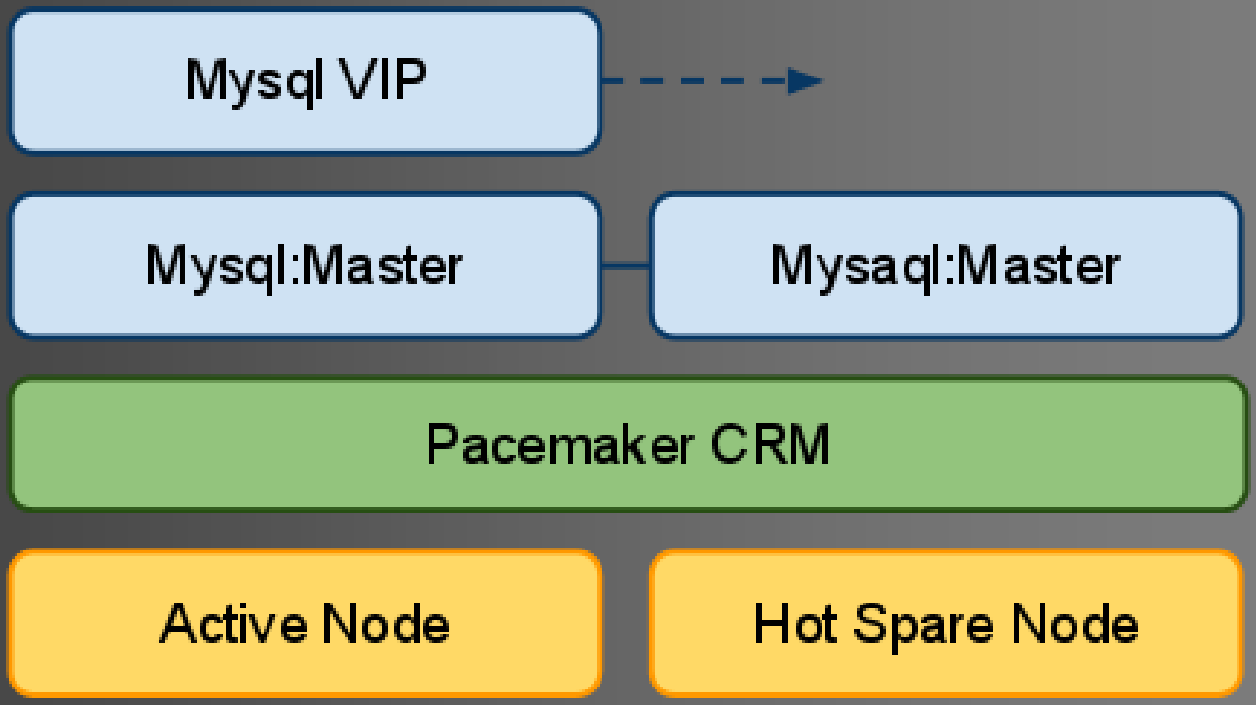

Split-Brain

- Кластер: 3 ноды A, B, C. Ресурс R находится на ноде A
- Теряется связь между A и остальными.
- B и C не знают, работает ли A (мертвый\живой).
- Поэтому они хотят перехватить управление ресурсом, чтобы пользователь не заметил возможной смерти A.
- Однако A жив (просто у него нет связи с остальными) и продолжает управлять ресурсом R.
- Две изолированных группы нод управляют одним ресурсом R одновременно, что может привести к повреждению ресурса.
- Возникает ситуация Split-Brain (“помутнение разума”).

Split-Brain

Иллюстрация
сломанного ресурса

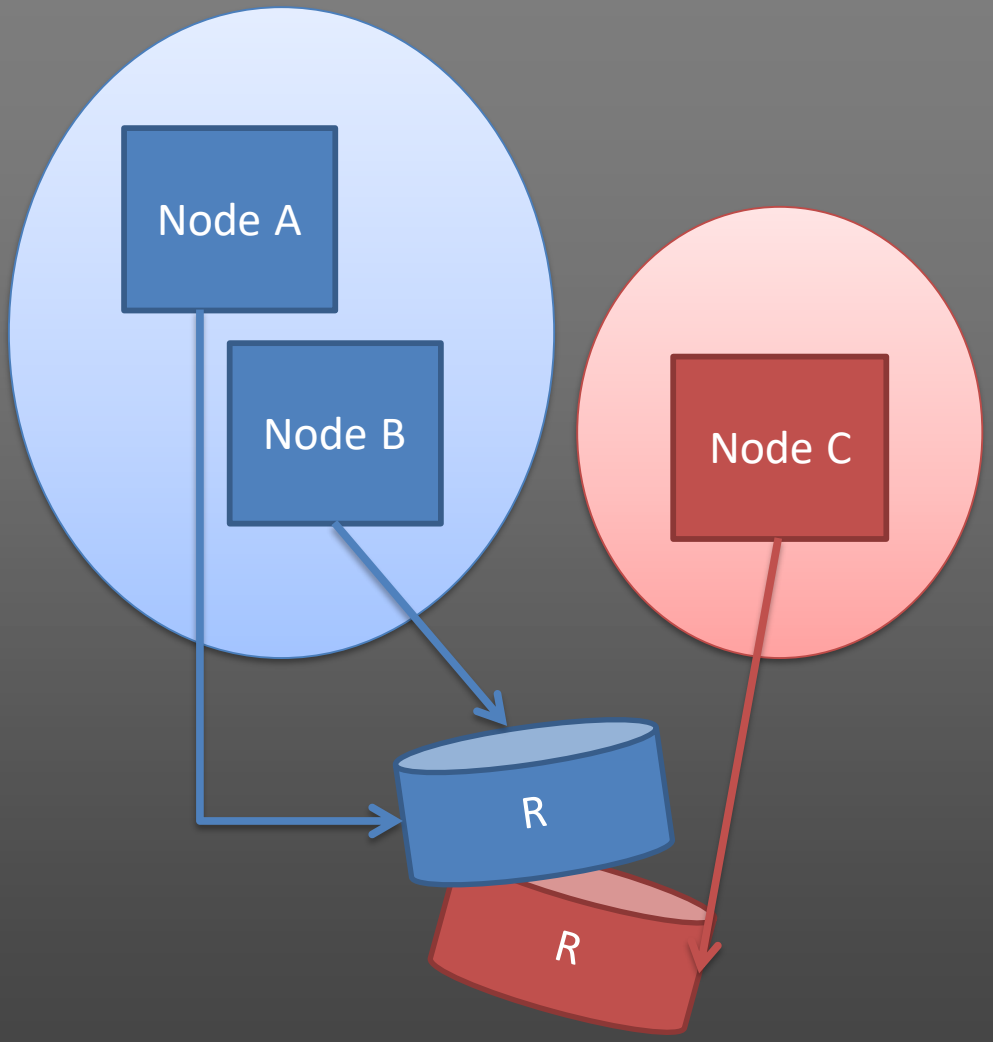

Fencing

Решение проблемы со Split-Brain: отрезать «выпавшей» ноде доступ к ресурсу и самим управлять им

Два типа fencing:

- Resource-fencing
- Node-fencing

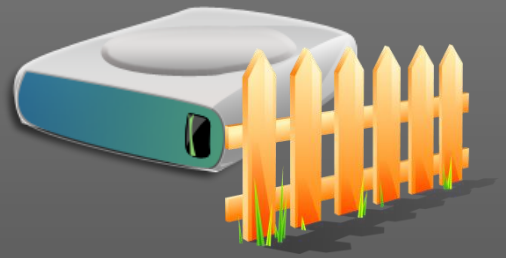

Fencing

Node fencing:

- Киллер на службе у кластера (тупо гасит «плохую» ноду)
- stonithd daemon
- STONITH plugin

STONITH devices:

- UPS
- PDU
- Blade power control device
- Lights-out devices
- Testing devices

Resource fencing

Resource fencing:
Кластер может иметь возможность контролировать определенные устройства (например, дисковые массивы, свитчи и т. д.) для того, чтобы запретить к ним доступ для «плохих» нод.

Quorum

При Split-Brain каждая независимая группа нод будет пытаться сделать STONITH другой группе нод.
Т. о. ничего работать не будет (все умрут).
Поэтому нужен некий механизм арбитража, для выяснения, кого именно «грохнуть».

Логика кворума проста: если я могу достучаться до более, чем N/2 нод, то нужно убить другую группу нод.

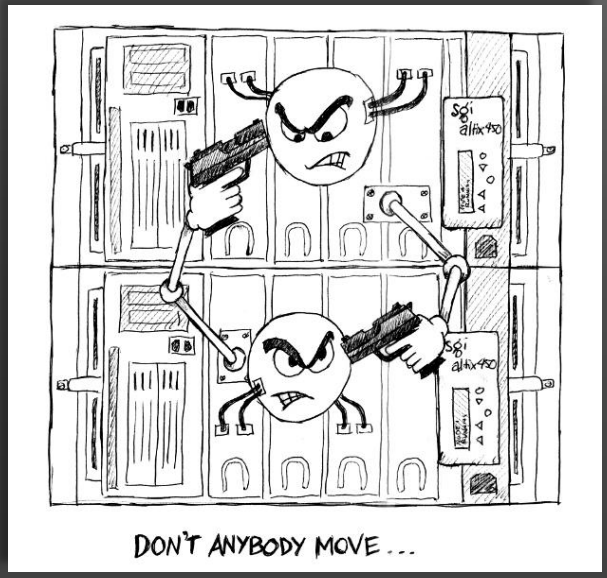

Поэтому: выключайте кворум и STONITH на 2-node-cluster, иначе все повиснет.

Архитектура HA-Cluster

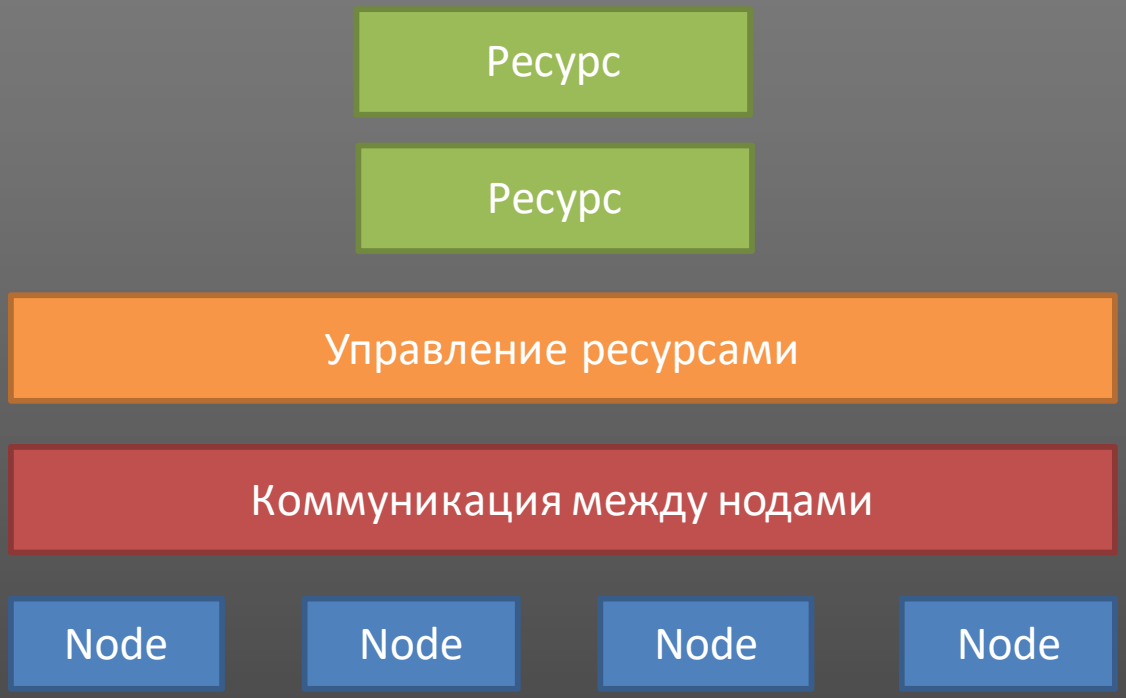

ПО HA-Cluster. Heartbeat

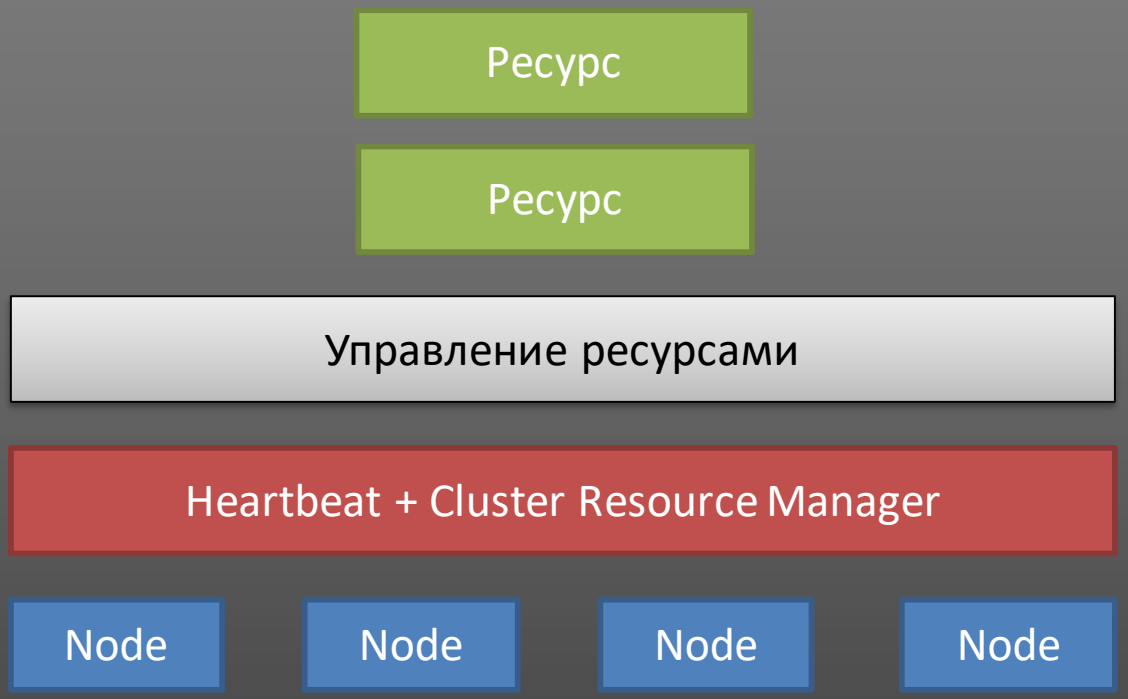

ПО HA-Cluster. Heartbeat + Pacemaker

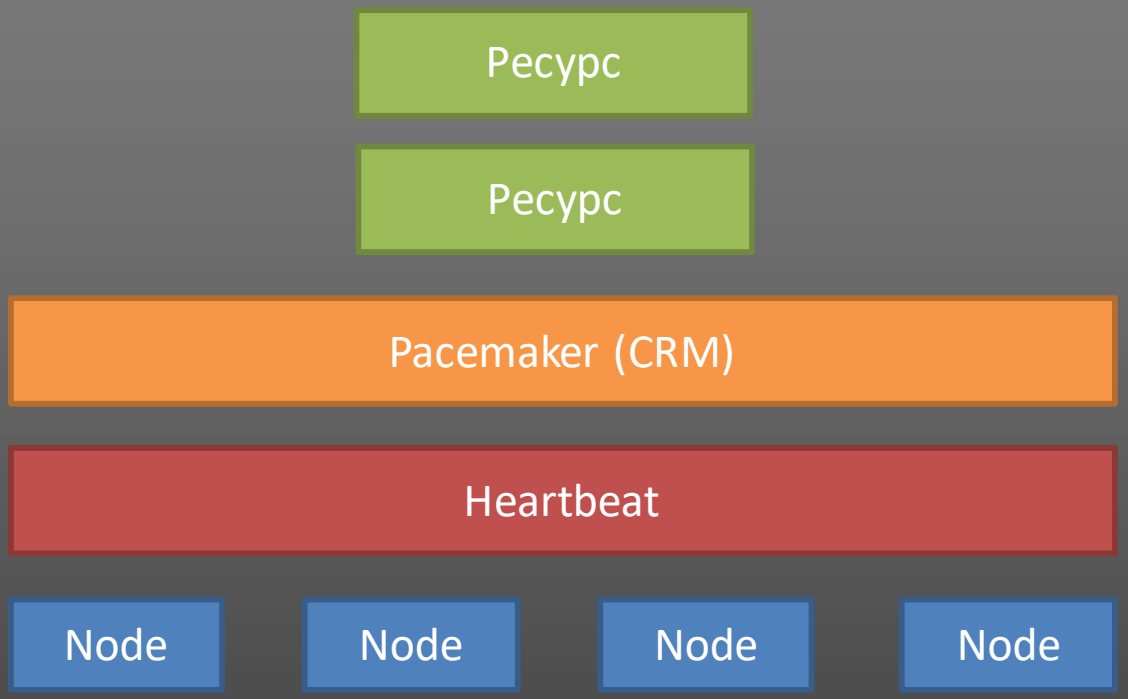

ПО HA-Cluster. Corosync + Pacemaker

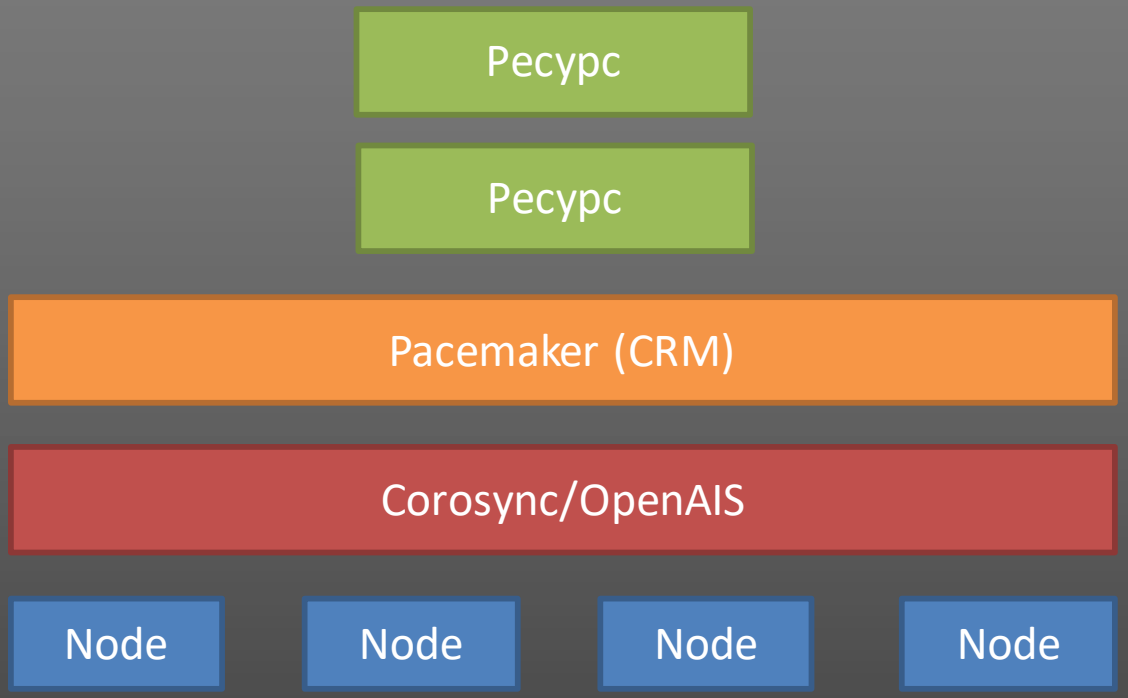

ПО HA-Cluster. Corosync + RGManager

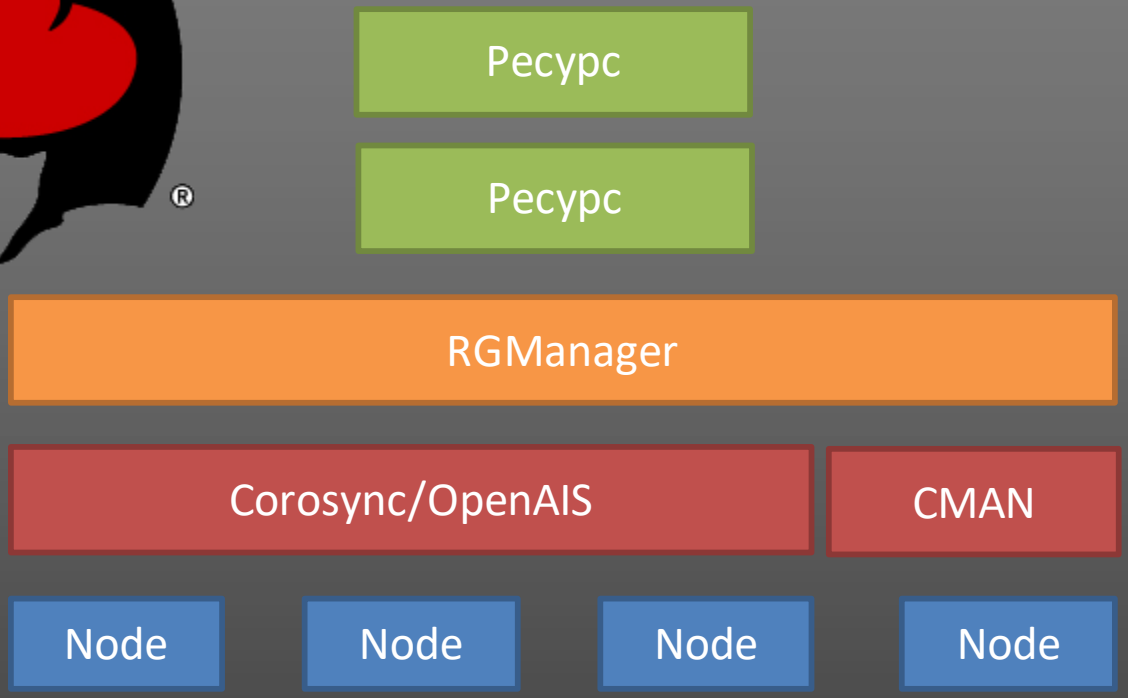

(RedHat Cluster Stack)

ПО HA-Cluster.

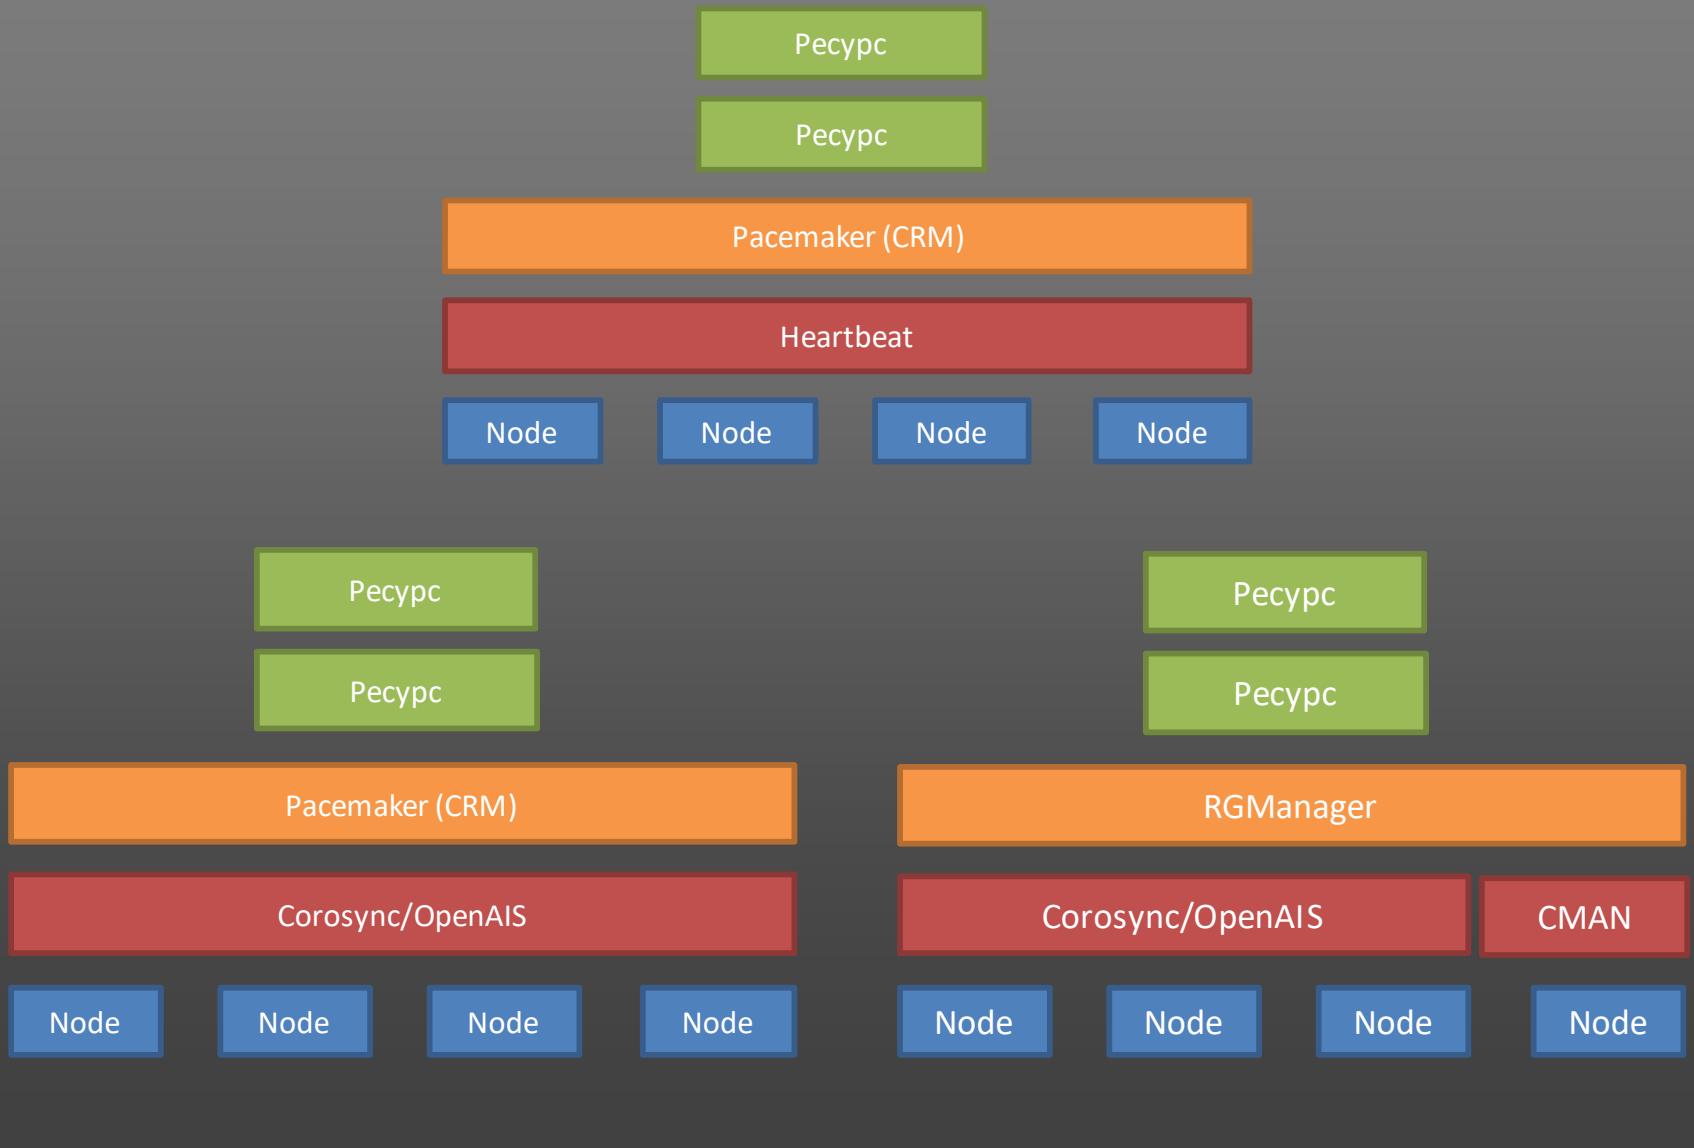

Что умеет Pacemaker

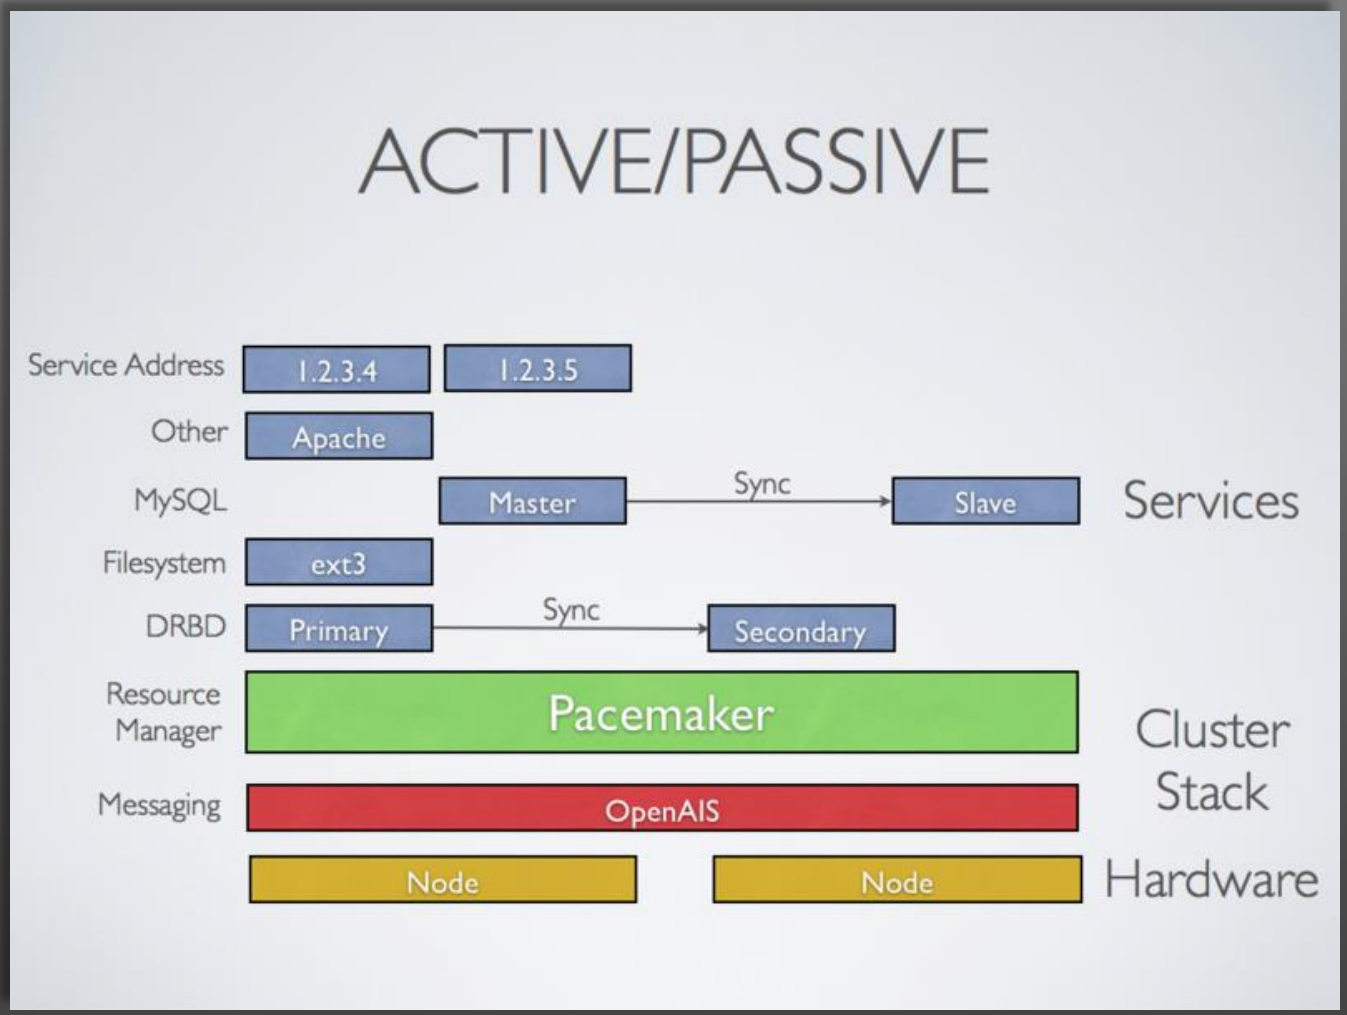

Что умеет Pacemaker

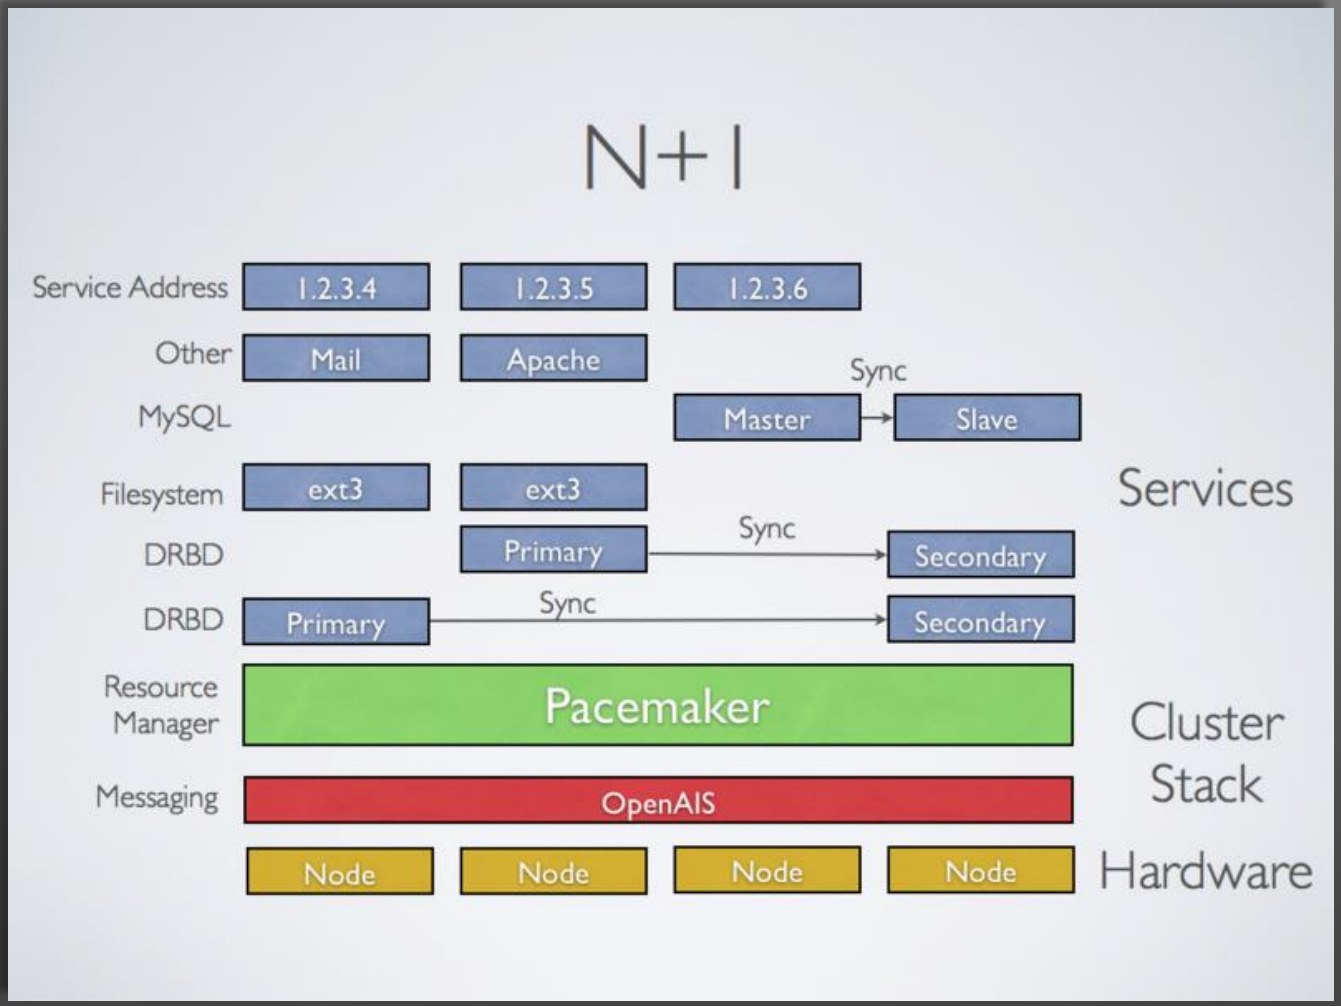

Что умеет Pacemaker

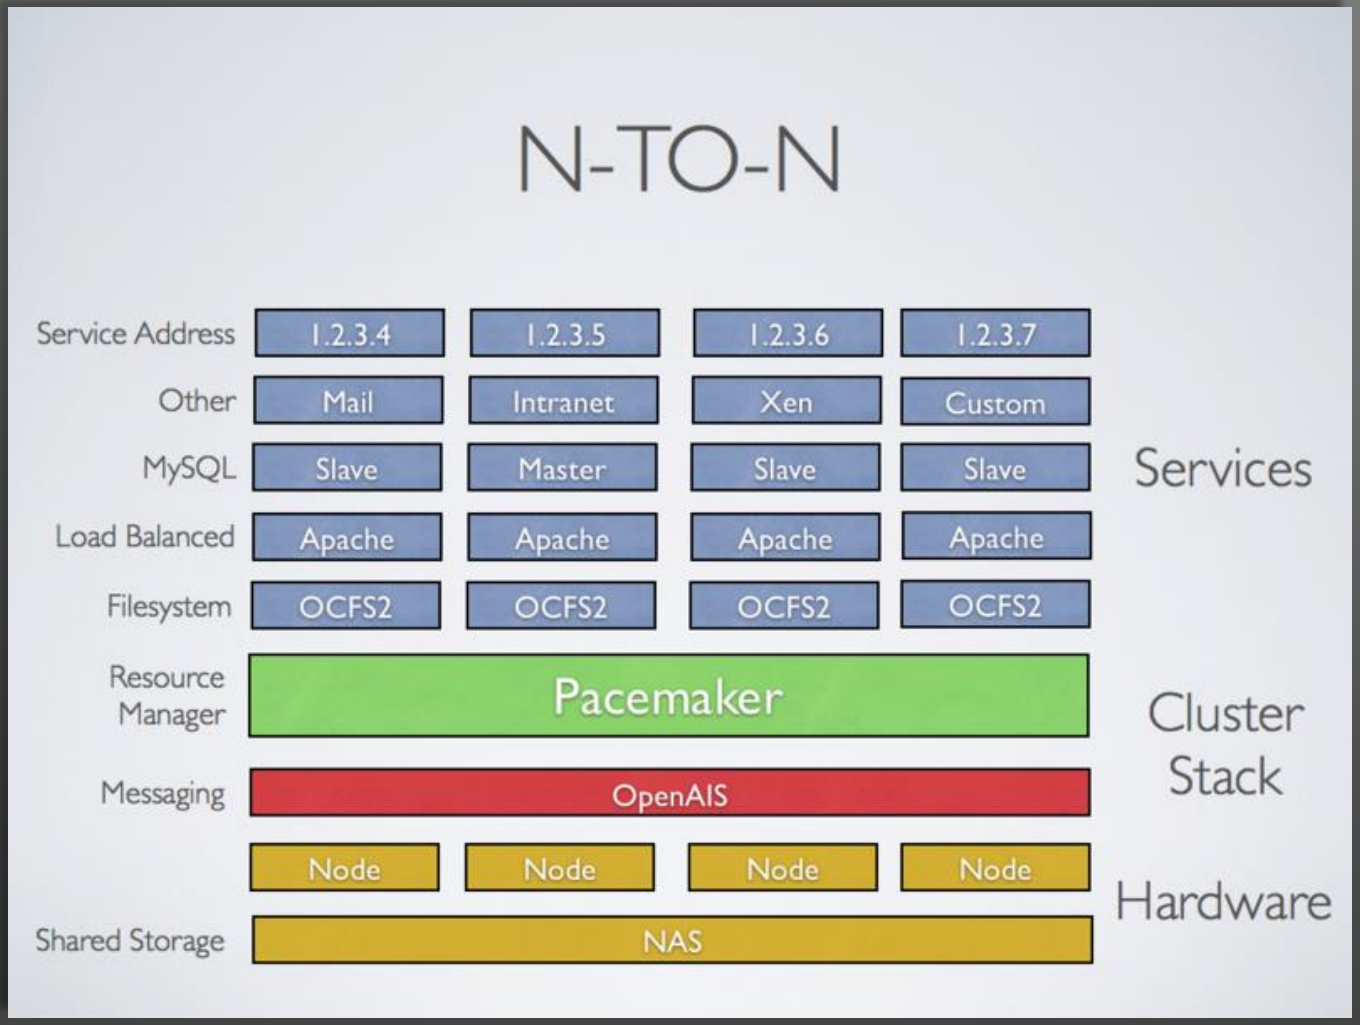

Что умеет Pacemaker

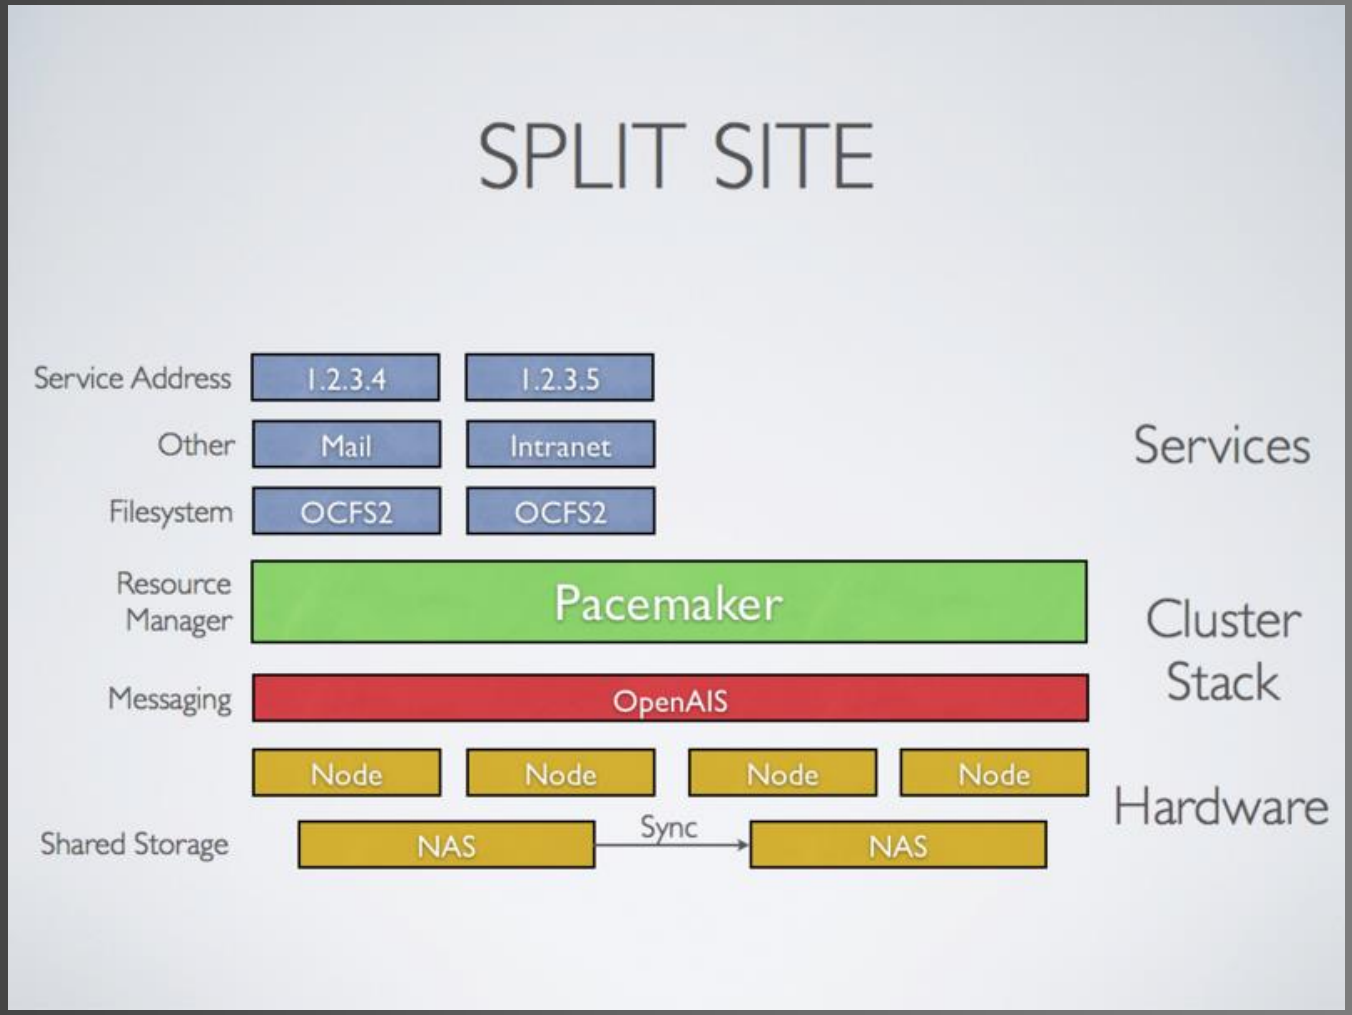

Задание для получения 5 на экзамене

- Сделать кластер с балансировкой нагрузки, похожий на тот, который демонстрировался на лекции
- Рекомендуемый кластерный стек: Pacemaker + Corosync или Heartbeat
- Рекомендуемый балансер: HAProxy
- Рекомендуемая ОС - Debian
- Виртуальные машины помогут вам (VmWare, VirtualPC, Xen, etc)
- В конце семестра нужно будет продемонстрировать работу кластера и объяснить шаги его настройки

Полезные ссылки

- Clusterlabs.org
- Linux-ha.com

Что почитать:

- Cluster from scratch
- Pacemaker explained